Μάθημα: Συστήματα Υπολογισμού Υψηλών Επιδόσεων (ΜΔΕ 646)

Ονοματεπώνυμο: Θεοδώρου Γεώργιος

ΑΕΜ: 0497

Report

1) Ακολουθεί πίνακας και σχετικό διάγραμμα μετρήσεων χρόνων, βάση του κώδικα της προηγούμενης άσκησης (με padding), με ενεργοποιημένες και μη των cache L1 και L2.

Tile_Width	Filter Radius	Image Size	GPU Time	dlcm=cg	dlcm=cs / dscm=wt
16x16	16	64 x 64	0.000022	0.000026	0.000021
16x16	16	128 x 128	0.000029	0.000035	0.000048
16x16	16	256 x 256	0.000065	0.000109	0.000174
16x16	16	512 x 512	0.000237	0.000412	0.000593
16x16	16	1024 x 1024	0.000971	0.001748	0.003047
16x16	16	2048 x 2048	0.005957	0.006355	0.021371
16x16	16	4096 x 4096	0.01682	0.026898	0.050627
16x16	16	8192 x 8192	0.060491	0.100153	0.16653

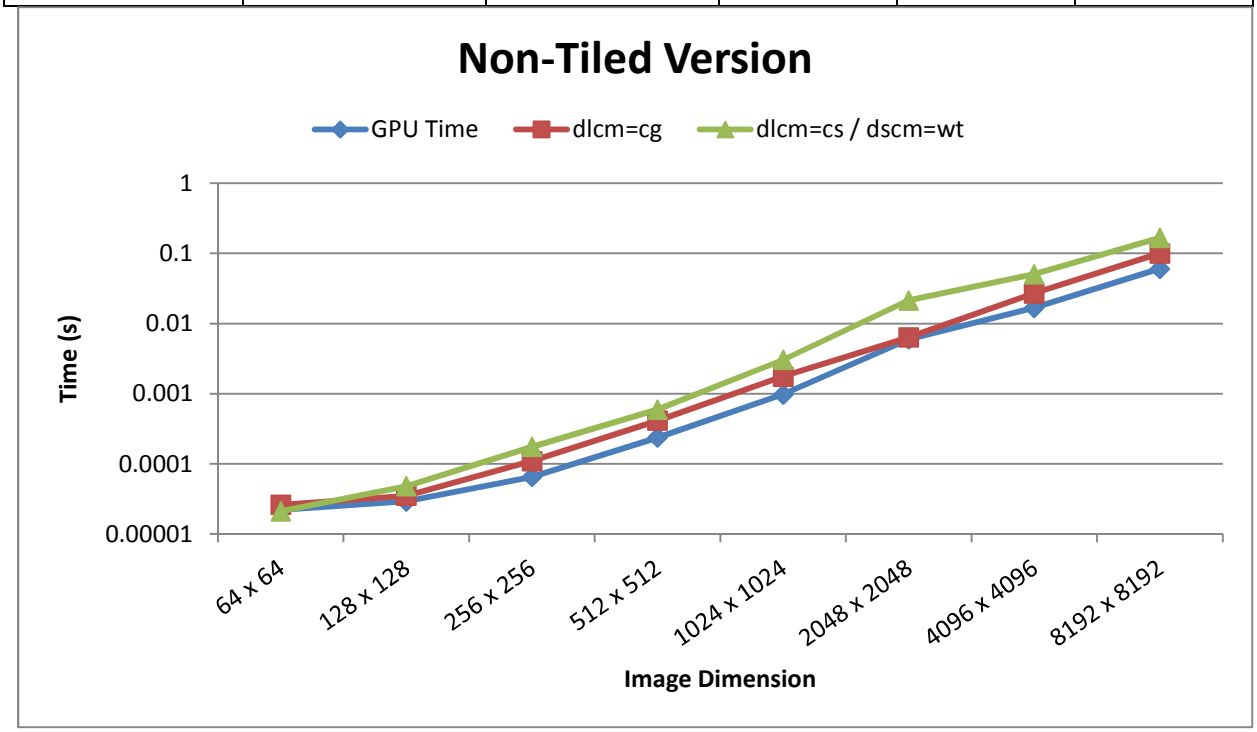

Παρατηρούμε αρχικά ότι όταν απενεργοποιούμε την L1 cache οι χρόνοι εκτέλεσης των kernel αυξάνονται αισθητά, δηλαδή έχουμε μια αύξηση περίπου 65%. Ενώ όταν απενεργοποιούμε και την L2 cache τότε οι χρόνοι εκτοξεύονται, με μια αύξηση περίπου 175%.

3) Κάθε kernel με Thread Block = 16x16 και Tile = 16x16 χρησιμοποιεί 10-12 registers, 3072 bytes shared memory και 56 bytes constant memory (Επιπλέον έχουμε δεσμεύσει και 132 bytes constant memory για τον πίνακα με το φιλτρο.).Το μέγιστο μέγεθος thread block που βορούμε να υποστηρίξουμε ετσι και αλλιώς ειναι 32χ32=1024 threads per block. Επομένως αφού θέλουμε το tile να είναι ίσο με το thread block , τότε βορούμε να χρησιμοποιήσουμε μέχρι και 32χ32 tile.(32χ32 ειναι η «καθαρή» διάσταση διότι στον row kernel θα πρέπει να προσθέσουμε ένα padding δεξία-αριστερά στο tile για να αποφύγουμε το divergence και αντίστοιχα στον column kernel πάνω-κάτω).

4) Ακολουθεί πίνακας και σχετικό διάγραμμα μετρήσεων χρόνων (σταθερή εικόνα 8192χ8192) για διάφορα μεγέθη tiles.

Filter Radius	Image_Width	Thread Block	Tile_W1	Tile_H1	Tile_W2	Tile_H2	GPU Time
16	8192	32x32	32	32	32	32	0.030857
16	8192	32x32	64	64	64	64	0.023221
16	8192	16x16	16	16	16	16	0.024366
16	8192	16x16	32	32	32	32	0.032905
16	8192	16x16	64	64	64	64	0.035246
16	8192	16x16	64	16	16	64	0.025193
16	8192	16x16	128	16	16	128	0.024573
16	8192	16x16	256	16	16	256	0.027638
16	8192	16x16	16	16	16	128	0.021172

Ο καλύτερος χρόνος επιτυγχάνεται με thread block 16x16 και tile ο πρώτος kernel 16x16, ενώ ο δεύτερος 16x128 . Σύμφωνα με το occupancy calculator ο πρώτος kernel έχει 100% occupancy, ενώ ο δεύτερος έχει 67%, διότι χρησιμοποιεί περισσότερους registers. Παρόλο όμως που το occupancy δεν ειναι 100% πετυγχάνουμε καλύτερους χρόνους.

Γενικά στην GTX 480 παρατηρήσα καλύτερους χρόνους με thread block 16x16 αντί για 32x32.

Filter Radius	Block_Tile	Image Size	GPU Time (Non-tiled)	GPU Time (Tiled)
16	16x16	128 x 128	0.000029	0.000015
16	16x16	256 x 256	0.000065	0.000033
16	16x16	512 x 512	0.000237	0.000093
16	16x16	1024 x 1024	0.000971	0.000343
16	16x16	2048 x 2048	0.005957	0.001427
16	16x16	4096 x 4096	0.01682	0.005391

16	16x16	8192 x 8192	0.060491	0.021172

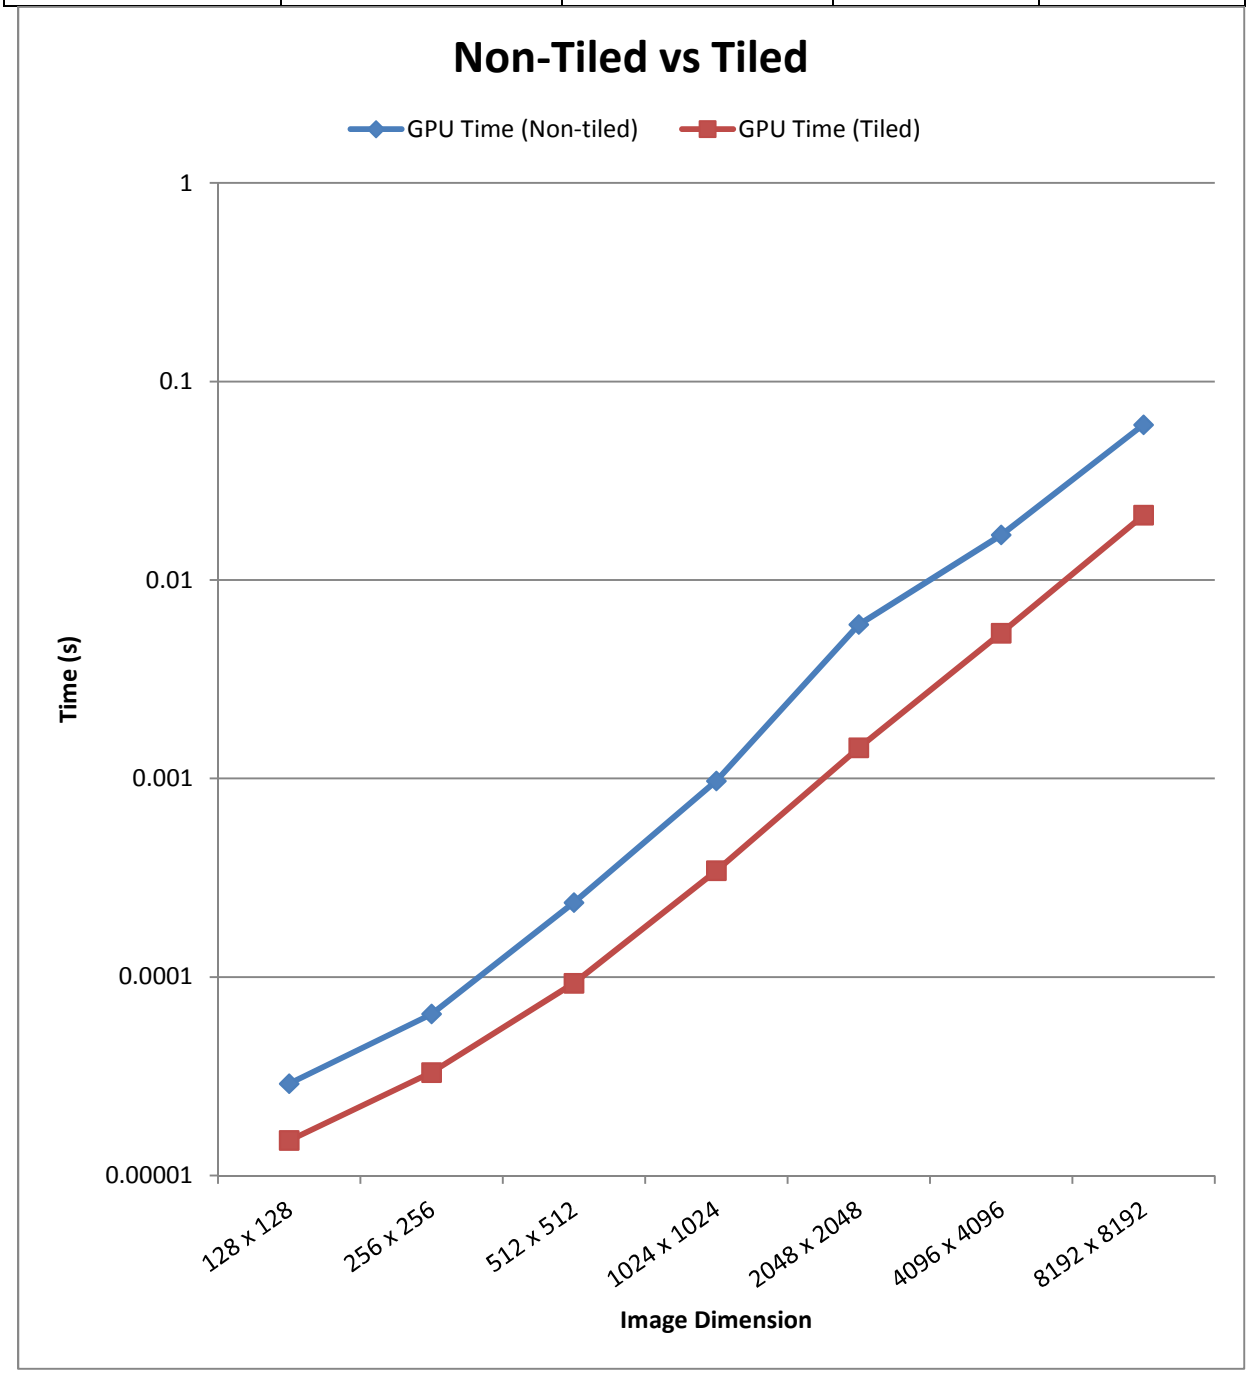

Παρατηρούμε ότι στην tile έκδοση των kernel έχουμε σημαντική βελτίωση του χρόνου εκτέλεσης των kernel, της τάξης του 65% . Η αύξηση αυτή είναι λογική εφόσον πλέον δεν κάνουμε load τα δεδομένα από την global memory κάθε φορά που τα χρησιμοποιούμε, αλλά τα κάνουμε μία φορά load στην shared memory και μετά τα παίρνουμε από την shared για να κάνουμε όλες τις πράξεις που χρειάζονται.

5)

- Για τον πρώτο kernel που διατρέχει την εικόνα κατά γραμμές, τα loads από global memory είναι ***image_size^2 * 3***, ενώ για τον δεύτερο kernel που διατρέχει την εικόνα κατά στήλες είναι ***image_size^2 * 1.25***. Τα loads από shared memory είναι ίδια και για τους 2 kernel ίσα με ***image_size^2 * filter_length*** και από constant memory ***image_size^2 * filter_length.***

  Όσο αυξάνουμε το tile τόσο αυξάνονται και τα στοιχεία που αποθηκεύουμε στην shared memory. Βασικά για να μειώσουμε το λόγο των αναγνώσεων της shared προς την global θα πρέπει να αυξήσουμε τα οφέλιμα 16χ16 κομάτια που φορτώνουμε στην shared σχετικα με το padding που χρειάζεται για το φίλτρο, δηλαδή όπως κάναμε στον δεύτερο kernel να έχει μεγάλο ύψος.

- Ο λόγος προσπελάσεων μνήμης για τον πρώτο kernel ειναι
  image_size^2 * 3 / image_size^2 * 2 * filter_length,
  ενώ για τον δεύτερο kernel είναι
  image_size^2 * 1.25 / image_size^2 * 2 * filter_length.
- Ο λόγος προσπελάσεων μνήμης ήτανε
  image_size^2 * 2 * filter_length / image_size^2 * 2 * filter_length = 1.
  Η διαφορά στους λόγους ειναι
  image_size^2 * 2 * filter_length - image_size^2 * 3 για τον πρώτο kernel και
  image_size^2 * 2 * filter_length - image_size^2 * 1.25 για τον δεύτερο kernel,
  δηλαδή με filter_length = 33 ειναι ίση με 66 * image_size^2 – 3 * image_size^2 και
  66 * image_size^2 – 1.25 * image_size^2 αντίστοιχα.

  Η διαφορά στους λόγους είναι ιδιαίτερα εμφανή, αφού οι λόγοι στην tiled έκδοση του κώδικα βελτιώθηκαν κατά **22 φορές** για τον πρώτο kernel και **52 φορές** για τον δεύτερο kernel αντιστοίχα, σε σχέση με τους λόγους στον non-tiled κώδικα.

6) Ακολουθεί πίνακας και σχετικό διάγραμμα μετρήσεων χρόνων, βάση του tiled κώδικα, με ενεργοποιημένες και μη των cache L1 και L2.

Filter Radius	Block_Tile	Shared_Tile	Image Size	GPU Time	dlcm=cg	dlcm=cs / dscm=wt
16	16x16	16x16 / 16x16	128 x 128	0.000015	0.000015	0.000016
16	16x16	16x16 / 16x16	256 x 256	0.000033	0.000031	0.000036
16	16x16	16x16 / 16x16	512 x 512	0.000093	0.000093	0.000105
16	16x16	16x16 / 16x16	1024 x 1024	0.000343	0.000342	0.000428
16	16x16	16x16 / 16x16	2048 x 2048	0.001427	0.001374	0.00223
16	16x16	16x16 / 16x16	4096 x 4096	0.005391	0.005425	0.007166

16	16x16	16x16 / 16x16	8192 x 8192	0.021172	0.021387	0.026841

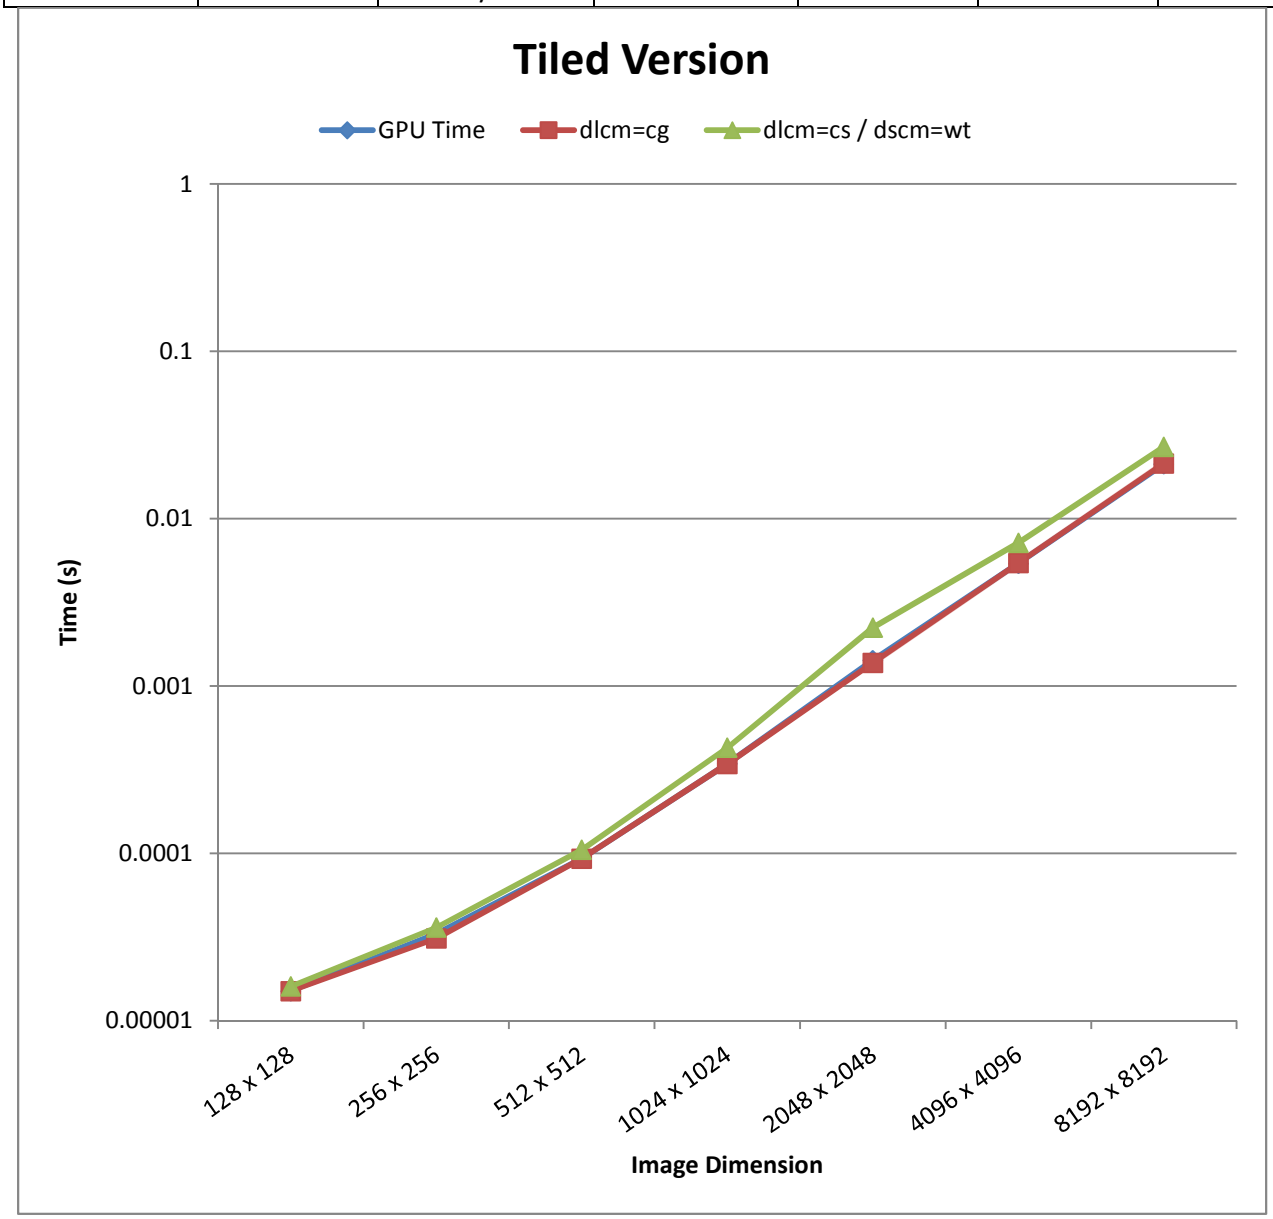

Αυτή τη φορά που χρησιμοποιούμε tiled kernel παρατηρούμε ότι όταν απενεργοποιούμε την L1 cache ο χρόνος δεν μεταβάλεται, αφού πλέον τα περισσότερα loads τα κάνουμε από την shared μνήμη και όχι απο την gobal όπως κάναμε στον non-tiled κώδικα.

Όταν απενεργοποιούμε και την L2 cache οι χρόνοι αυξάνονται κατά 30%. Η διαφορά με τον non-tiled κώδικα είναι εμφανής αφου τα loads από την global memory μειώνονται πάρα πολύ.

7) Ακολουθεί πίνακας και σχετικό διάγραμμα μετρήσεων χρόνων, βάση του tiled κώδικα, με αντικατάσταση των floats με doubles.

Filter Radius	Block_Tile	Shared_Tile	Image Size	GPU Time (floats)	GPU Time (doubles)
16	16x16	16x16 / 16x16	128 x 128	0.000015	0.00003
16	16x16	16x16 / 16x16	256 x 256	0.000033	0.000084
16	16x16	16x16 / 16x16	512 x 512	0.000093	0.00027
16	16x16	16x16 / 16x16	1024 x 1024	0.000343	0.001006
16	16x16	16x16 / 16x16	2048 x 2048	0.001427	0.003959
16	16x16	16x16 / 16x16	4096 x 4096	0.005391	0.015635
16	16x16	16x16 / 16x16	8192 x 8192	0.021172	out of memory

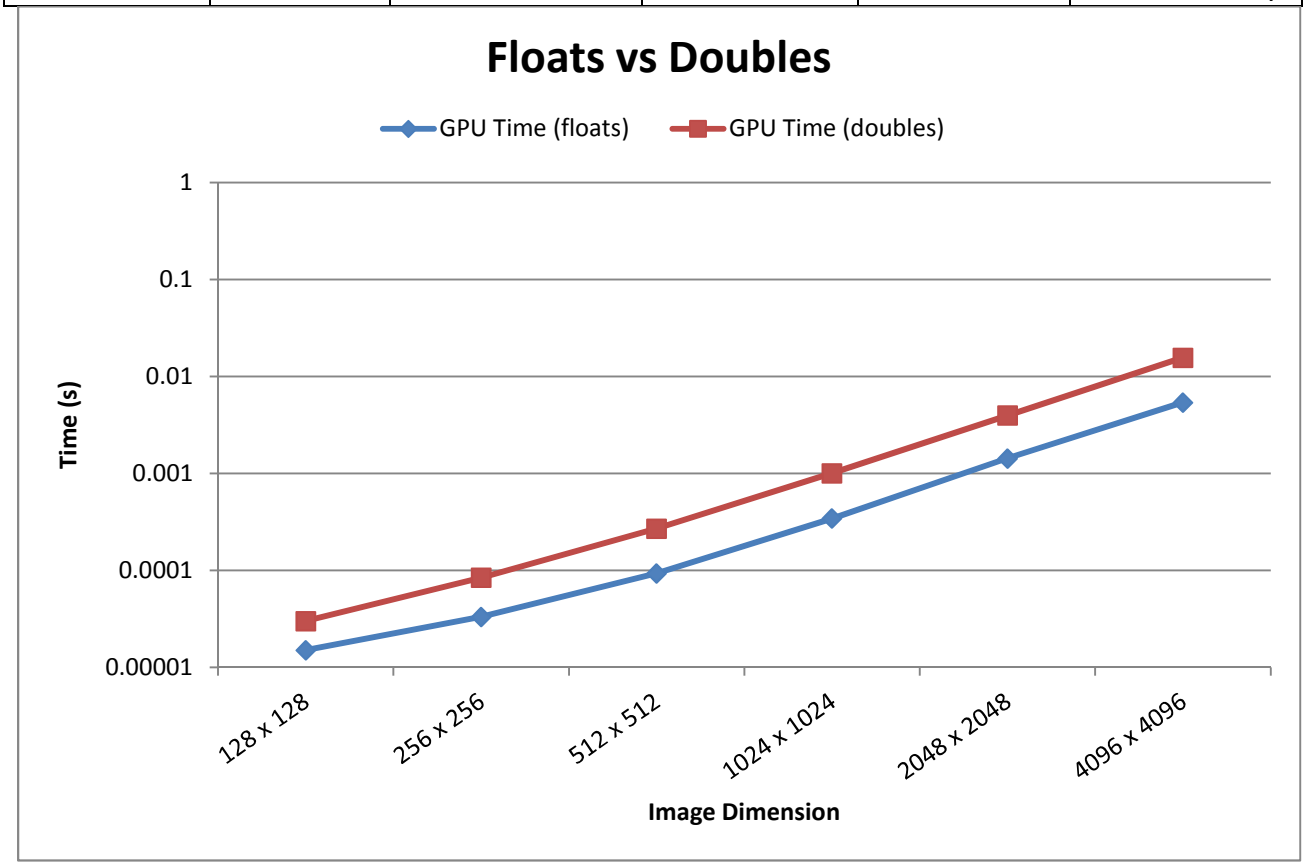

Εφόσον κάθε double αντιστοιχεί σε 8 byte, ενώ κάθε float αντιστοιχεί σε 4 byte είναι λογικό ότι το tile που χρησιμοποιούμε χρειάζεται διπλάσια shared memory για να αποθηκευτεί. Το μέγιστο μέγεθος tile που μπορούμε να χρησιμοποιήσουμε είναι 64χ64 (δηλαδή

(64 * (64 + 16 * 2)) * 8 byte shared memory)

έτσι ώστε να χρησιμοποιήσουμε και τα 48K shared μνήμης.